Московский авиационный институт
(национальный исследовательский университет)

Институт №8 «Компьютерные науки и прикладная математика»

Кафедра 806 «Вычислительная математика и программирование»

Лабораторная работа №5 по курсу «Информационный поиск»

Студент:	Е. Р. Николаева
Преподаватель:	А. А. Кухтичев
Группа:	М8О-401Б-22
Дата:	
Оценка:	
Подпись:	

Москва, 2026

Лабораторная работа №5 «Закон Ципфа»

Для своего корпуса необходимо построить график распределения терминов по частотностям в логарифмической шкале, наложить на этот график закон Ципфа. Объяснить причины расхождения. В качестве дополнительного задания, можно (но необязательно) подобрать константы для закона Мандельброта, наложить полученный график на график распределения терминов по частотностям. Привести выбранные константы.

1 Описание работы

В данной лабораторной работе требовалось построить распределение терминов по частотностям для подготовленного корпуса документов, изобразить это распределение в логарифмической шкале и наложить на него закон Ципфа. Также необходимо было объяснить причины расхождения между реальным распределением терминов и идеальной зависимостью, задаваемой законом Ципфа.

2 Постановка задачи

В рамках лабораторной работы необходимо:

- обработать весь корпус документов;
- выделить термины по тем же правилам токенизации, которые использовались ранее;
- вычислить частоту каждого термина во всём корпусе;
- отсортировать термины по убыванию частоты;
- построить график зависимости частоты термина от его ранга;
- представить график в логарифмической шкале;
- наложить на него закон Ципфа;
- объяснить расхождения между реальными данными и идеальной моделью.

3 Теоретические сведения

Закон Ципфа описывает одно из характерных свойств естественного языка. В простейшей форме он утверждает, что частота слова обратно пропорциональна его рангу в упорядоченном по частоте списке:

$$f(r) \approx \frac{C}{r^s},$$

где:

- r — ранг термина;
- $f(r)$ — частота термина;

- C — константа;
- s — параметр распределения, который в идеализированном случае часто близок к 1.

Если построить график зависимости частоты от ранга в логарифмической шкале, распределение, подчиняющееся закону Ципфа, будет близко к прямой линии:

$$\log f(r) = \log C - s \log r.$$

4 Исходные данные

Для построения распределения использовался тот же корпус научных статей по тематике обработки естественного языка, который был подготовлен ранее. В расчётах применялись те же правила токенизации, что и в предыдущей лабораторной работе. Это важно для согласованности результатов, так как закон Ципфа исследуется не для абстрактных слов вообще, а именно для тех терминов, которые реально выделяются выбранным токенизатором.

5 Методика построения распределения

Работа выполнялась в несколько этапов:

1. чтение всех текстовых файлов корпуса;
2. токенизация каждого документа;
3. подсчёт общей частоты каждого термина во всём корпусе;
4. сортировка терминов по убыванию частоты;
5. построение последовательности рангов;
6. вычисление идеальной и подогнанной Zipf-кривой;
7. сохранение результатов в CSV-файл;
8. построение графика в логарифмической шкале.

6 Реализация

Программа была реализована на языке C++. Она использует ту же функцию токенизации, что и в предыдущих работах, а затем подсчитывает частоту каждого термина в коллекции.

Для хранения частот использовалась ассоциативная структура вида:

```
unordered_map<string,long long>term_freq;
```

При обработке корпуса частоты обновлялись следующим образом:

```
for (const string& tok : tokens) {
term_freq[tok]++;
}
```

После завершения подсчёта частоты всех терминов собирались в массив и сортировались по убыванию:

```
vector<long long>freqs;
for (const auto& kv : term_freq) {
freqs.push_back(kv.second);
}

sort(freqs.begin(),freqs.end(),greater<long long>());
```

Таким образом, позиция элемента в отсортированном массиве определяла ранг термина, а значение элемента — его частоту.

7 Подгонка закона Ципфа

Кроме идеальной кривой с $s = 1$, в работе строилась и подогнанная кривая, параметры которой оценивались по реальным данным. Для этого использовалась линейная регрессия в логарифмических координатах:

$$\log f(r) = a + b \log r.$$

Из коэффициентов регрессии вычислялись параметры:

$$s = -b, \qquad C = e^a.$$

Соответствующий фрагмент реализации имел вид:

```
double x = std::log(rank);
double y = std::log(freq);

sum_x += x;
sum_y += y;
sum_xx += x * x;
sum_xy += x * y;
```

После этого по стандартным формулам линейной регрессии вычислялись коэффициенты прямой, а затем параметры подогнанного распределения Ципфа.

8 Результаты выполнения

В результате обработки корпуса были получены следующие характеристики:

- количество обработанных документов: 40000;
- общее количество токенов: 192744697;
- количество уникальных терминов: 1030452;
- размер входного текста: 1201818038 байт;
- время выполнения программы: 59.103998 сек;
- частота самого частого термина C: 12060746;
- оценённый параметр s: 1.415964;
- оценённый параметр C для подогнанной кривой: 198397969.499931.

Полученные данные были сохранены в CSV-файл, а затем использованы для построения графика распределения терминов по частотности и наложения на него двух кривых:

- идеальной кривой Ципфа при $s = 1$;
- подогнанной кривой с параметром $s = 1.415964$.

9 Анализ результатов

Полученное значение параметра $s = 1.415964$ больше единицы. Это означает, что в данном корпусе частоты терминов убывают быстрее, чем в классическом идеальном случае закона Ципфа. Иными словами, наиболее частые термины имеют очень большие частоты, однако по мере роста ранга частоты падают достаточно резко.

В логарифмической шкале реальное распределение демонстрирует Zipf-подобное поведение, однако заметно отклоняется от идеальной зависимости. Особенно это заметно при сравнении с кривой $s = 1$.

10 Причины расхождения с законом Ципфа

Расхождения между реальными данными и идеальной моделью объясняются несколькими причинами.

1 Специфика корпуса

Корпус состоит не из текстов общего языка, а из научных статей по обработке естественного языка. В таких текстах встречается большое количество специализированных терминов, названий моделей, методов, редких обозначений и аббревиатур. Это делает распределение менее “естественным” по сравнению с корпусами общего языка.

2 Большое число редких терминов

Для научного корпуса характерно наличие большого числа низкочастотных терминов, встречающихся один или несколько раз. Это приводит к сильному утяжелению хвоста распределения и влияет на оценённое значение параметра s.

3 Влияние токенизации

Распределение строилось не по словам в лингвистическом смысле, а по токенам, выделенным выбранным токенизатором. В частности:

- сохранялись дефисные формы;
- сохранялись отдельные числовые конструкции;
- не выполнялось специальное объединение сокращений;
- URL и технические обозначения могли разбиваться на несколько токенов.

Из-за этого в словаре появляется дополнительное число редких терминов, что также влияет на форму распределения.

4 Тематика и повторяемость терминов

В корпусе по NLP очень часто встречаются такие термины, как `language`, `translation`, `model`, `data`, `training`, `attention`. Их частоты оказываются выше, чем это было бы в корпусе общего языка, что искажает верхнюю часть распределения по сравнению с идеальной моделью.

11 Вывод по результатам

Несмотря на отклонения от идеальной зависимости, распределение терминов в корпусе в целом демонстрирует Zipf-подобное поведение. Это подтверждается близостью графика к линейной зависимости в логарифмической шкале и возможностью удовлетворительно аппроксимировать его степенной функцией.

Однако параметр распределения для реального корпуса оказался заметно больше единицы, что указывает на более резкое убывание частот. Основные причины этого связаны со специализированной тематикой корпуса, большим числом редких терминов и особенностями токенизации.

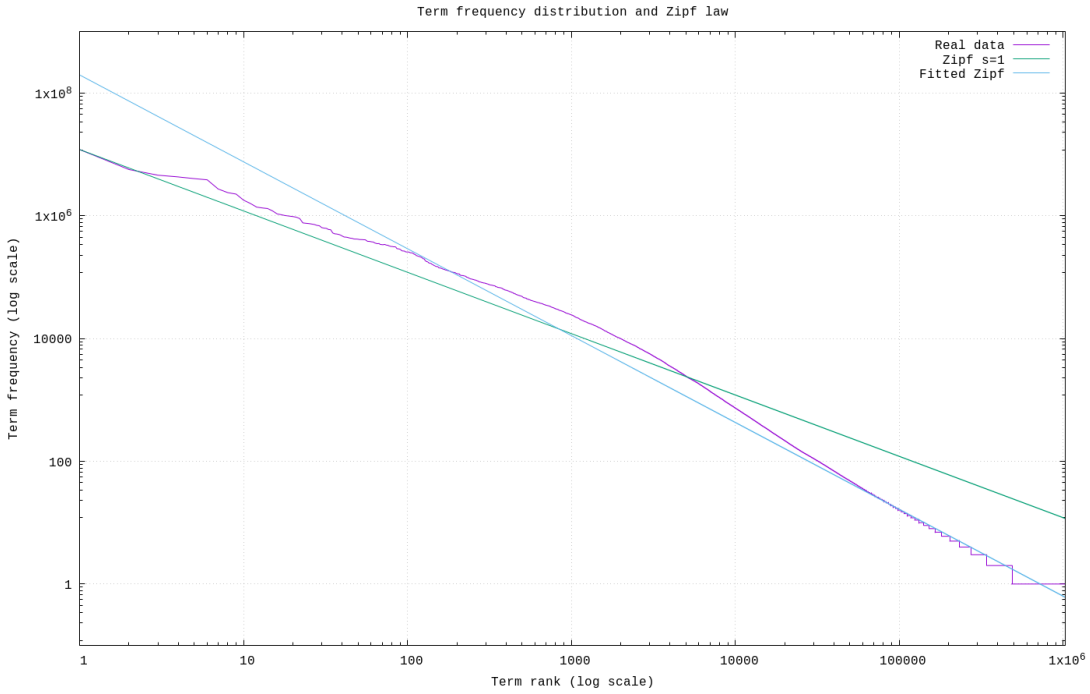

12 Выводы

В результате выполнения лабораторной работы было построено распределение терминов по частотности для подготовленного корпуса документов и выполнено сравнение этого распределения с законом Ципфа. Эксперимент показал, что корпус в целом демонстрирует Zipf-подобное поведение: наиболее частые термины встречаются очень часто, а по мере увеличения ранга их частота убывает по степенному закону. Вместе с тем было установлено, что реальное распределение заметно отличается от идеальной модели с параметром $s = 1$. Для данного корпуса был получен параметр $s = 1.415964$, что свидетельствует о более резком убывании частот. Это объясняется тематической узостью корпуса, большим количеством специализированных и редких терминов, а также особенностями выбранной токенизации. Таким образом, лабораторная работа подтвердила применимость закона Ципфа к реальному тематическому корпусу, но одновременно показала, что для специализированных коллекций документов наблюдаются систематические отклонения от идеализированной модели.

Список литературы

[1] Маннинг К., Рагхаван П., Шютце Х. *Введение в информационный поиск.* — М.: Вильямс, 2011. — 528 с.

[2] Джурафски Д., Мартин Д. Х. *Обработка речи и языка.* — Электронный ресурс.

[3] Хипс Г. *Законы распределения словаря и частот в текстах.* — Электронный ресурс.