Московский авиационный институт
(национальный исследовательский университет)

Институт №8 «Компьютерные науки и прикладная математика»

Кафедра 806 «Вычислительная математика и программирование»

Лабораторная работа №7 по курсу «Информационный поиск»

Студент:	Е. Р. Николаева
Преподаватель:	А. А. Кухтичев
Группа:	М8О-401Б-22
Дата:	
Оценка:	
Подпись:	

Москва, 2026

Лабораторная работа №7 «Булев поиск»

Нужно реализовать ввод поисковых запросов и их выполнение над индексом, получение поисковой выдачи. Синтаксис поисковых запросов:

- Пробел или два амперсанда, «», соответствуют логической операции «И».
- Две вертикальных «палочки», «||» – логическая операция «ИЛИ»
- Восклицательный знак, «!» – логическая операция «НЕТ»
- Могут использоваться скобки.

Парсер поисковых запросов должен быть устойчив к переменному числу пробелов, максимально толерантен к введённому поисковому запросу. Примеры запросов:[московский авиационный институт], [(красный || желтый) автомобиль], [руки !ноги].

Для демонстрации работы поисковой системы должен быть реализован веб-сервис, реализующий базовую функциональность поиска из двух страниц:

- Начальная страница с формой ввода поискового запроса.
- Страница поисковой выдачи, содержащая в себе форму ввода поискового запроса, 50 результатов поиска в виде текстов заголовков документов и ссылок на эти документы, а так же ссылку на получение следующих 50 результатов. Так же должна быть реализована утилита командной строки, загружающая индекс и выполняющая поиск по нему для каждого запроса на отдельной строчке входного файла. В отчёте должно быть отмечено:
  - Скорость выполнения поисковых запросов.
  - Примеры сложных поисковых запросов, вызывающих длительную работу.
  - Каким образом тестировалась корректность поисковой выдачи.

1 Описание работы

В данной лабораторной работе требовалось реализовать ввод поисковых запросов и их выполнение над ранее построенным индексом, а также получение поисковой выдачи. По условию задания необходимо было поддержать булев поиск с операциями логического И, ИЛИ и НЕ, а также скобки. Кроме того, требовалось обеспечить устойчивый разбор запросов при переменном числе пробелов, реализовать утилиту командной строки для пакетного поиска и веб-сервис с базовой функциональностью поисковой системы.

2 Постановка задачи

В рамках лабораторной работы необходимо:

- реализовать разбор булевых поисковых запросов;
- поддержать следующий синтаксис:
  - пробел или `&&` — логическая операция И;
  - `||` — логическая операция ИЛИ;
  - `!` — логическая операция НЕ;
  - скобки для задания порядка вычисления;
- обеспечить толерантность парсера к различному числу пробелов;
- выполнять поиск по ранее построенному бинарному индексу;
- сформировать поисковую выдачу на основе прямого индекса;
- реализовать консольную утилиту пакетной обработки запросов;
- реализовать веб-сервис с формой ввода и страницей выдачи.

3 Основа поиска

Булев поиск был реализован поверх бинарного индекса, построенного в предыдущей лабораторной работе. Используются следующие компоненты индекса:

- `index_header.bin` — заголовок индекса;
- `forward.bin` — прямой индекс с заголовками и путями документов;
- `vocab.bin` — словарь термов;
- `postings.bin` — postings-списки.

Прямой индекс используется для формирования человекочитаемой выдачи, а словарь и postings-списки — для вычисления результата булева выражения.

4 Поддерживаемый синтаксис запросов

Реализованный парсер поддерживает следующие элементы:

- пробел как операцию И;
- явную операцию И в виде `&&`;
- операцию ИЛИ в виде `||`;
- операцию НЕ в виде `!`;
- круглые скобки.

Примеры корректных запросов:

- `machine translation`;
- `machine && translation`;
- `machine || translation`;
- `machine !translation`;
- `(question || answering) && !speech`.

Поддержка пробела как операции И делает синтаксис более удобным для пользователя и соответствует формулировке задания.

5 Этапы обработки поискового запроса

Обработка запроса в системе выполняется в несколько этапов:

1. лексический разбор строки запроса;
2. нормализация и токенизация термов;
3. вставка неявных операций И между соседними выражениями;
4. преобразование инфиксной записи в обратную польскую запись;
5. вычисление булева выражения по postings-спискам;
6. формирование итоговой выдачи.

6 Лексический разбор

На первом этапе входная строка запроса разбивается на элементарные лексемы. При этом выделяются:

- термы;
- операторы `AND`, `OR`, `NOT`;
- символы `(` и `)`.

Внутренне пользовательские обозначения преобразуются к унифицированной форме:

- `&&` превращается в `AND`;
- `||` превращается в `OR`;
- `!` превращается в `NOT`.

Основной фрагмент кода лексического разбора имеет вид:

```
if (c == '&'&& i + 1 <query.size() && query[i + 1] == '&') {
flush_cur();
out.push_back("AND");
++i;
continue;
}
```

Аналогично обрабатываются `||`, `!` и скобки.

7 Нормализация и токенизация термов

После лексического разбора отдельные текстовые фрагменты проходят через ту же токенизацию, что использовалась ранее в системе. Это важно, поскольку запрос и документы должны обрабатываться единообразно. Благодаря этому поиск выполняется по тем же термам, которые реально присутствуют в индексе.

8 Вставка неявного И

Поскольку по условию задания обычный пробел также соответствует логической операции И, после нормализации выражения система вставляет неявный оператор `AND` между соседними термами или подвыражениями.

Например, запрос

```
machine translation
```

преобразуется во внутреннее представление

```
machine AND translation
```

Соответствующая логика реализована следующим образом:

```
bool prev_can_end_expr = is_term_like(prev) || prev == ")";
bool cur_can_start_expr = is_term_like(cur) || cur == "(" || cur == "NOT";

if (prev_can_end_expr && cur_can_start_expr) {
out.push_back("AND");
}
```

Это делает парсер более толерантным и удобным для пользователя.

9 Преобразование в обратную польскую запись

Для вычисления булевых выражений использовался алгоритм преобразования инфиксной записи в обратную польскую запись. Такой подход удобен тем, что:

- учитывает приоритеты операций;
- поддерживает скобки;
- упрощает последующее вычисление выражения.

Приоритеты операций были выбраны следующими:

- `NOT` — самый высокий приоритет;
- `AND` — средний;
- `OR` — самый низкий.

Это соответствует стандартной логике булевой алгебры.

10 Вычисление булева выражения

После получения обратной польской записи выражение вычисляется с помощью стека. Если встречается терм, из словаря извлекается соответствующий postings-список. Если встречается оператор, выполняется булева операция над множествами документов.

Используются три основные операции:

- объединение списков документов — для `OR`;
- пересечение списков документов — для `AND`;
- дополнение по универсальному множеству документов — для `NOT`.

Например, пересечение реализовано следующим образом:

```
while (i <a.size() && j <b.size()) {
if (a[i] == b[j]) {
out.push_back(a[i]);
++i; ++j;
} else if (a[i] <b[j]) {
++i;
} else {
++j;
}
}
```

Так как postings-списки упорядочены по идентификаторам документов, операции пересечения и объединения выполняются эффективно.

11 Формирование поисковой выдачи

После вычисления булева выражения получается список идентификаторов документов. Далее по прямому индексу извлекаются:

- заголовок документа;
- путь или ссылка на документ.

Именно эта информация затем выводится пользователю как поисковая выдача.

12 Консольная утилита

Для выполнения требований задания была реализована отдельная консольная утилита пакетной обработки запросов. Она:

- загружает индекс один раз;
- читает запросы по одному на строку из стандартного ввода;
- выполняет поиск для каждого запроса;
- выводит найденные результаты.

Запуск утилиты выполняется следующим образом:

```
.\boolean_search_cli index_binary <queries.txt
```

Такой режим удобен для тестирования корректности, замера времени и пакетной проверки запросов.

13 Веб-сервис

Кроме консольной утилиты, был реализован веб-сервис с базовой функциональностью поиска. Сервис включает две страницы:

- начальную страницу с формой ввода запроса;
- страницу поисковой выдачи.

Страница выдачи содержит:

- форму повторного ввода запроса;
- первые 50 результатов поиска;
- заголовки документов и ссылки на них;
- ссылку для перехода к следующим 50 результатам.

Веб-сервис был реализован как удобная оболочка над булевым поиском по построенному индексу. Это позволило продемонстрировать работу системы в форме, близкой к реальной поисковой машине.

14 Тестирование корректности

Корректность работы поисковой выдачи проверялась несколькими способами:

- сравнение результатов для запросов с пробелом и с явным `&&`;
- проверка работы `OR` на объединении результатов;
- проверка работы `NOT` на исключении документов;
- проверка влияния скобок на порядок вычисления;
- ручной анализ результатов для нескольких содержательных запросов.

Например, сравнивались запросы:

- `machine translation`;
- `machine && translation`;
- `machine || translation`;
- `machine !translation`;
- `(question || answering) && !speech`.

Также проверялось, что изменение порядка операций с помощью скобок действительно приводит к изменению результата.

15 Скорость выполнения запросов

Скорость выполнения запросов определяется несколькими факторами:

- размером postings-списков;
- числом операций пересечения и объединения;
- использованием отрицания;
- сложностью структуры выражения.

Как правило, простые запросы из двух или трёх термов выполняются быстро. Более длительную работу вызывают запросы:

- с очень частотными термами;
- с большим числом операций `OR`;
- с широким отрицанием `NOT`;
- с глубоко вложенными скобками.

Например, потенциально более тяжёлыми являются запросы, включающие частые слова и широкие объединения:

- `language || model || data || training`;
- `!(language || model)`;
- `((machine || translation) && (question || answering)) || data`.

16 Результаты выполнения

В результате выполнения лабораторной работы был реализован булев поиск по ранее построенному бинарному индексу. Система поддерживает:

- пробел как операцию И;
- операцию `&&`;
- операцию `||`;
- операцию `!`;
- круглые скобки;
- консольный интерактивный режим;
- пакетный поиск через CLI-утилиту;
- веб-сервис с базовой поисковой выдачей.

Таким образом, все основные требования лабораторной работы были выполнены.

- Index loaded.
- Documents: 40000
- Terms: 1030452
- Enter boolean query: machine translation
- Results: 14254 path=acl$_f ulltext_d ocs_0 00005.txttion foraJapanese-Hungarianmachinetrans$
  $acl_f ulltext_d ocs_0 00007.txtandCurrentOutcomeoftheUnitGraphsFrameworkpath =$
  $acl_f ulltext_d ocs_0 00012.txtranslatorspath = acl_f ulltext_d ocs_0 00013.txtcessibleSemanticRoleL$
  $acl_f ulltext_d ocs_0 00015.txtdaptation foranArabic/FrenchNewsTranslationSystembyLightly$
  $SupervisedTrainingpath = acl_f ulltext_d ocs_0 00016.txtAugmentationofBilingualTerminolo$
  $acl_f ulltext_d ocs_0 00017.txttatoCompareth eDifficultyofUsingStatisticalMachineTranslati$
  $Pairspath = acl_f ulltext_d ocs_0 00021.txtproachesinPhrase-BasedStatisticalMachineTrans$
  $acl_f ulltext_d ocs_0 00022.txtsystem fordetectingglobalhealtheventspath = acl_f ulltext_d ocs_0 0002$

- Enter boolean query: question answering Results: 7022 path=acl$_f ulltext_d ocs_0$00007$.txtandCu$
$acl_f ulltext_d ocs_0$00018$.txtinein formationretrieval forPolishopen-domainQuestionAnswer$
$acl_f ulltext_d ocs_0$00023$.txt-and-MergeWordnetConstruction : plWordNetandaCompariso$
$acl_f ulltext_d ocs_0$00043$.txtgComprehensiontoDialogueStateTracking : BridgingtheGappath$
$acl_f ulltext_d ocs_0$00062$.txtogModelsforConversationalUnderstandingpath = acl_f ulltext_d ocs$
$acl_f ulltext_d ocs_0$00075$.txttiveSummarizationUsinganIsingMachineTowardsReal-$
$timeGenerationofEfficientandCoherentDialogueScenariospath = acl_f ulltext_d ocs_0$00076.
$acl_f ulltext_d ocs_0$00094$.txtRelabelingforRobustandDiverseVoiceAppsRecommendationinIn$
$acl_f ulltext_d ocs_0$00096$.txttrainedmodelforcustomerservicedialogues$
- Enter boolean query: named entity recognition Results: 4204 path=acl$_f ulltext_d ocs_0$00022$.txts$
$acl_f ulltext_d ocs_0$00023$.txt-and-MergeWordnetConstruction : plWordNetandaCompariso$
$acl_f ulltext_d ocs_0$00044$.txtval-2022Task11 : Complexnamedentityrecognitionusingalateral$
$acl_f ulltext_d ocs_0$00047$.txtNounPhraseExtractionforTextAnalysispath = acl_f ulltext_d ocs_0 0$
$acl_f ulltext_d ocs_0$00055$.txtInteractioninanAmbientAssistedLivingLabpath = acl_f ulltext_d ocs$
$acl_f ulltext_d ocs_0$00069$.txt--aStepTowardsDeclarativeDeepRelationalLearningpath =$
$acl_f ulltext_d ocs_0$00071$.txtWordNethierarchiestoLinkedInandTwitterpath = acl_f ulltext_d ocs$
- Enter boolean query: transformer attention Results: 3821 path=acl$_f ulltext_d ocs_0$00038$.txtyCr$
$acl_f ulltext_d ocs_0$00059$.txtAPersona-GroundedChit-ChatGenerationFrameworkpath =$
$acl_f ulltext_d ocs_0$00062$.txtogModelsforConversationalUnderstandingpath = acl_f ulltext_d ocs$
$EventGraphSchemaInductionwithPathLanguageModelingpath = acl_f ulltext_d ocs_0$00073$.t$
$OrientedDialogSystemspath = acl_f ulltext_d ocs_0$00082$.txtfier--AccuracyandEntropyRed$
$acl_f ulltext_d ocs_0$00089$.txtnforDialogueStateTrackingpath = acl_f ulltext_d ocs_0$00124$.txtnLa$
$acl_f ulltext_d ocs_0$00146$.txtchmarktoCaptureOlfactorySituationsoverTimepath =$
$acl_f ulltext_d ocs_0$00164$.txtkforBuildingProductionNLPSystems$
- Enter boolean query: dependency parsing Results: 6183 path=acl$_f ulltext_d ocs_0$00003$.txtation$
$acl_f ulltext_d ocs_0$00006$.txtictiveDependencyParsingunderReal-TimeConditionspath =$
$acl_f ulltext_d ocs_0$00030$.txtapaneseLight-verbConstructionsBasedonLexicalConceptualStr$
$acl_f ulltext_d ocs_0$00037$.txtgorithmforClassificationofSemi-StructuredTextusingtheFreq$
$acl_f ulltext_d ocs_0$00040$.txtSEMESharedTask2018 : Multi-WordExpressionDetectionUsi$
$Short-TermMemoryNetworksandGraph-BasedDecodingpath = acl_f ulltext_d ocs_0$00042$.t$
$acl_f ulltext_d ocs_0$00063$.txteryofGenderedLanguagethroughLatent-VariableModelingpath$
$acl_f ulltext_d ocs_0$00065$.txtQuantifiersinJapanese-to-EnglishMachineTranslationpath =$
$acl_f ulltext_d ocs_0$00069$.txt--aStepTowardsDeclarativeDeepRelationalLearningpath =$
$acl_f ulltext_d ocs_0$00072$.txtQuantifiersinJapanese-to-EnglishMachineTranslation$
- Enter boolean query: machine translation Results: 14254 path=acl$_f ulltext_d ocs_0$00005$.txttion$
$Hungarianmachinetranslationsystempath = acl_f ulltext_d ocs_0$00007$.txtandCurrentOutcom$
$acl_f ulltext_d ocs_0$00012$.txtranslatorspath = acl_f ulltext_d ocs_0$00013$.txtcessibleSemanticRoleL$
$acl_f ulltext_d ocs_0$00015$.txtdaptationforanArabic/FrenchNewsTranslationSystembyLightly$

$SupervisedTrainingpath = acl_fulltext_docs_0 00016.txtAugmentationofBilingualTerminolo$
$acl_fulltext_docs_0 00017.txttatoCompareth eDifficultyofUsingStatisticalMachineTranslati$
$Pairspath = acl_fulltext_docs_0 00021.txtproachesinPhrase-BasedStatisticalMachineTrans$
$acl_fulltext_docs_0 00022.txtsystemfordetectingglobalhealtheventspath = acl_fulltext_docs_0 0002$

- Enter boolean query: machine || translation Results: 25399 path=acl$_f ulltext_d ocs_0$00002$.txton$
$acl_fulltext_docs_0 00005.txttionforaJapanese-Hungarianmachinetranslationsystempath =$
$acl_fulltext_docs_0 00007.txtandCurrentOutcomeoftheUnitGraphsFrameworkpath =$
$acl_fulltext_docs_0 00008.txtnerationofGeneSummarypath = acl_fulltext_docs_0 00011.txtlledNa$
$acl_fulltext_docs_0 00012.txtranslatorspath = acl_fulltext_docs_0 00013.txtcessibleSemanticRoleL$
$acl_fulltext_docs_0 00014.txtingBilingualTerminologybyTakingAdvantageoftheConceptualSy$
$acl_fulltext_docs_0 00015.txtdaptationforanArabic/FrenchNewsTranslationSystembyLightly$
$SupervisedTrainingpath = acl_fulltext_docs_0 00016.txtAugmentationofBilingualTerminolo$

- Enter boolean query: machine !translation Results: 8617 path=acl$_f ulltext_d ocs_0$00002$.txtonof$
$acl_fulltext_docs_0 00008.txtnerationofGeneSummarypath = acl_fulltext_docs_0 00020.txtKitche$
$DoweNeedSentimentDomainAdaptation?path = acl_fulltext_docs_0 00028.txt -$
$aToolsetforRule-basedRecognitionofSemanticRelationsBetweenNamedEntitiespath =$
$acl_fulltext_docs_0 00030.txtapaneseLight-verbConstructionsBasedonLexicalConceptualStru$
$acl_fulltext_docs_0 00037.txtgorithmforClassificationofSemi-StructuredTextusingtheFreq$
$acl_fulltext_docs_0 00043.txtgComprehensiontoDialogueStateTracking : BridgingtheGappath$
$acl_fulltext_docs_0 00046.txtsambiguationbySubstitutionpath = acl_fulltext_docs_0 00052.txtAhyb$
$acl_fulltext_docs_0 00053.txtcCoherenceinTopicModels$
- Enter boolean query: (machine || translation) !speech Results: 16910 path=acl$_f ulltext_d ocs_0$00
$acl_fulltext_docs_0 00005.txttionforaJapanese-Hungarianmachinetranslationsystempath =$
$acl_fulltext_docs_0 00008.txtnerationofGeneSummarypath = acl_fulltext_docs_0 00011.txtlledNa$
$acl_fulltext_docs_0 00012.txtranslatorspath = acl_fulltext_docs_0 00014.txtingBilingualTerminol$
$acl_fulltext_docs_0 00016.txtAugmentationofBilingualTerminologiespath = acl_fulltext_docs_0 0$
$Pairspath = acl_fulltext_docs_0 00018.txtineinformationretrievalforPolishopen-$
$domainQuestionAnsweringsystempath = acl_fulltext_docs_0 00019.txtdicate -$
$ArgumentStructureforJapaneseVerbstoDealwithGranularityofVerbMeanings$

17 Выводы

В результате выполнения лабораторной работы был реализован булев поиск по ранее построенному бинарному индексу. Система поддерживает основные логические операции И, ИЛИ и НЕ, а также круглые скобки и неявную операцию И, задаваемую пробелом. Это делает поисковый синтаксис удобным для пользователя и соответствующим условиям задания. В работе были реализованы как интерактивный

консольный режим, так и пакетная утилита для выполнения набора запросов. Кроме того, был разработан веб-сервис с формой ввода и страницей выдачи. Проверка показала корректную работу булевых операций и устойчивость разбора запросов. Реализованный модуль поиска может использоваться как полноценная часть дальнейшей поисковой системы.

Список литературы

[1] Маннинг К., Рагхаван П., Шютце Х. *Введение в информационный поиск.* — М.: Вильямс, 2011. — 528 с.

[2] Уиттен И., Моффат А., Белл Т. *Управление гигабайтами: сжатие и индексирование документов и изображений.* — Электронный ресурс.

[3] Джурафски Д., Мартин Д. Х. *Обработка речи и языка.* — Электронный ресурс.

[4] Flask. — URL: `https://flask.palletsprojects.com/`

[5] SQLite. — URL: `https://www.sqlite.org/`